

概率论 - 常见概念

作者：Klein White

时间：2025-08-1

概要：

频率与概率

频率：n次实验中，事件A发生了k次，则称A的频率为k/n

概率：当n趋近于无穷大，此时A的频率会趋于某个值，这个值即为A发生的概率

古典概型（古典概率模型）

- 每次随机试验的结果只能是有限的n个，且这n个结果有且只有一个发生
- 每个样本发生的概率相等

概率的古典定义：事件A包含古典概型中n个样本点的k个，那么称事件A的概率为k/n

几何概型（几何概率模型）

几何概型是基于几何度量（如长度、面积、体积等）来计算概率的一种方法，假设样本空间是一个测度有限的空间，事件A发生的概率为P(A)，P(A)与区域的度量成正比，与A在空间中的分布位置和形状无关。则P(A)等于A在样本空间的面积占比

它适用于试验的所有可能结果是某个几何区域中的点，且每个点出现的可能性相同的情况。

全概率公式

全概率公式将其复杂的概率求解分解为若干个简单事件的概率来求解。全概率公式的核心思想是利用样本空间的划分来简化复杂事件的概率计算。

假设 $A_1, A_2, \dots, A_n$ 是样本空间P的一个划分

则对于事件B, 有 $P(B) = \sum_{i=1}^n P(A_i) \cdot P(B|A_i)$

贝叶斯公式

贝叶斯公式用于在已知某些条件概率的情况下，计算事件的后验概率。贝叶斯公式的核心思想是通过已知的先验概率和条件概率，更新对某个事件的概率估计。

比如下面，基于对于事件 A 的先验概率，然后通过引入关于 B 的条件概率，来更新对于事件 A 的概率估计。常用于医学诊断（判断患病概率）、机器学习的贝叶斯模型等

假设 $A_1, A_2, \dots, A_n$ 是样本空间 P 的一个划分

$$\text{则对于事件 } B, \text{ 有 } P(A_i|B) = \frac{P(B|A_i) \cdot P(A_i)}{\sum_{i=1}^n P(A_i) \cdot P(B|A_i)}$$

其他的地方也有写成：

$$\text{对于事件 } A \text{ 和 } B, \text{ 则 } P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

其中 $P(A|B)$ 是后验概率， $P(A)$ 是先验概率， $P(B|A)$ 是条件概率

事件的独立性

当 $P(AB) = P(A)P(B)$ 时，说明事件 A 和 事件 B 相互独立

比如前后抛两次骰子

多事件的独立性不仅需要事件之间两两独立，甚至可能会有三个事件也需要独立的情况，类推即可

离散型随机变量及概率分布

离散型随机变量也就是随机变量的取值是有限且离散的，则每一个取值都会对应一个概率值
常见的离散型随机变量概率分布有：

两点分布

- 两点分布：只进行一次实验，实验的结果只有两种情况，其概率分别为 p 和 1-p

二项分布

在相同条件下，进行 n 次实验，各次的实验都两两独立，互不影响，则这样的实验叫做 n 重独立试验，或 **伯努利试验**

- 二项分布：n 重伯努利实验，事件 A 发生的概率为 p，不发生的概率为 1-p，则 n 次实验中，事件 A 发生 k 次的概率为：

$$P(X = k) = C_n^k p^k (1 - p)^{n-k}, \text{二项体现在这个式子}$$

n=1时，即为两点分布。

二项分布的均值为 np，方差为 np(1-p)

泊松分布

泊松定理：对于 n 重伯努利试验，假设单次试验中事件 A 发生的概率为 λ
则当 n 趋于无穷大时候， n 次试验中，事件 A 发生 k 次的概率为：

$$\frac{e^{-\lambda} \lambda^k}{k!}, \text{ 这样的分布形式叫做泊松分布}$$

λ 表示单位时间事件的平均发生率（平均发生次数）

泊松分布的均值和方差皆为 λ

泊松分布用于描述在一段时间或空间内，某一事件发生特定次数的概率
适用于各个事件发生独立且随机

泊松分布其实是当二项分布的试验次数很大的时候，可以使用它来近似二项分布，当 n 较大而 p 较小的时候，可以让 $\lambda = np$ ，然后带入计算

累计概率分布函数（分布函数）

形如 $F(x) = P(X \leq x)$

连续型随机变量及其概率密度

对于连续型的随机变量，由于其取值有无数个，所以一般使用概率密度函数来描述：

$$F(x) = \int_{-\infty}^x f(t) dt$$

$f(x)$ 称为 X 的概率密度函数

理解起来参考前缀和，如 $F(a < X < b) = \int_a^b f(t) dt$

常见的连续型随机变量的概率分布有：

连续分布

$$f(x) = \begin{cases} \frac{1}{b-a}, & \text{if } a < x < b \\ 0, & \text{others} \end{cases}$$

指数分布

$$\text{概率密度函数为: } f(x) = \begin{cases} \lambda e^{-\lambda x}, & \text{if } x \geq 0 \\ 0, & x < 0 \end{cases}$$

常用于生物寿命、元器件寿命等估计。

指数分布是**唯一的“无记忆性”的连续型分布**，即：

如果随机变量 $X \sim E(\lambda)$ ，则对于任意 $s > 0, t > 0$

$$P\{X > s + t | X > s\} = P\{X > t\}$$

正态分布

概率密度函数为：
$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

该分布的均值为 μ ，方差为 σ^2

一般记为 $X \sim N(\mu, \sigma^2)$

对于 $X \sim N(\mu, \sigma^2)$ ，则 $Z = \frac{X - \mu}{\sigma} \sim N(0, 1)$

ps ：互相独立的随机变量满足可加性，当 X_1 和 X_2 相互独立

$Z = \alpha X_1 + \beta X_2$ ， Z 的期望为 $\alpha\mu_1 + \beta\mu_2$ ，方差为 $\alpha^2\sigma_1^2 + \beta^2\sigma_2^2$

多维随机变量及其概率密度

以二维的为例，假设 X, Y 是定义在同一空间的两个随机变量，那么对于这两个随机变量，其联合分布函数为：

$$F(x, y) = P\{X \leq x, Y \leq y\}$$

其中当某个变量趋于无穷大时，即可得到关于另一个变量的边缘分布函数

$$\text{如：} F_X(x) = \lim_{y \rightarrow \infty} F(x, y)$$

对于离散型的随机变量的话，这样的 $F(X=x, Y=y)$ 叫做联合分布率，对应的也有边缘分布律

同理也有概率密度函数，形如：

$$F(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(u, v) du dv$$

称为联合概率密度

同理当某个变量趋于无穷大时，就得到关于另一个变量的边缘概率密度

二维均匀分布

设 D 为平面区域，其面积为 s ，二维随机变量 (X, Y) 的联合概率密度为：

$$f(x) = \begin{cases} \frac{1}{s}, & (x, y) \in D \\ 0, & \text{others} \end{cases}$$

二维正态分布

见书本，非重点

随机变量的独立性

对于 n 维随机变量 $(X_1, X_2, \dots, X_n)$ 的联合分布函数为 $F(x_1, x_2, \dots, x_n)$
 $F_i(x_i)$ 为 X_i 的边缘分布函数，如果对于任意的 n 个实数 $x_1, x_2, \dots, x_n$

都有
$$F(x_1, x_2, \dots, x_n) = \prod_{i=1}^n F_i(x_i)$$

则称这 n 个随机变量相互独立

只要存在一种情况的 n 个数的取值使得等式不成立，则独立性不成立
以二维随机变量为例，其独立性的充要条件为： $F(x, y) = F_X(x)F_Y(y)$

期望 Expectation

期望是随机变量最基本的数学特征，反应了随机变量的平均取值，这种平均取值是随机变量的所有可能值以概率为权重的加权平均

对于离散型随机变量，其分布律为 $P(X = x_k) = p_k$

若 $\sum_{i=1}^n x_i p_i$ 收敛，则说明期望存在

对于连续型随机变量，其期望定义为：

$$E(X) = \int_{-\infty}^{\infty} x f(x) \, dx$$

对于随机变量函数 $g(x)$ ，其数学期望为： $E[g(x)] = \int_{-\infty}^{\infty} g(x) f(x) \, dx$

方差

设 X 是一个随机变量，若 $E[X - E(X)]^2$ 存在，则称其为 X 的方差，记为：

$$D(x) = E[X - E(X)]^2$$

对于离散型随机变量， $D(X) = \sum_{i=1}^n [x_i - E(X)]^2$

对于连续型随机变量，也可以使用 $D(X) = E(X^2) - E(X)^2$ 计算

常用的随机变量的期望和方差：

分布名称	概率密度函数（PDF）或概率质量函数（PMF）	数学期望 $E(X)$	方差 $\text{Var}(X)$
伯努利分布 Bernoulli(p)	$P(X = 1) = p, \quad P(X = 0) = 1 - p$	p	$p(1 - p)$
二项分布 Binomial(n, p)	$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}$	np	$np(1 - p)$
泊松分布 Poisson(λ)	$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}$	λ	λ

分布名称	概率密度函数 (PDF) 或概率质量函数 (PMF)	数学期望 $E(X)$	方差 $\text{Var}(X)$
几何分布 Geometric(p)	$P(X = k) = (1 - p)^{k-1}p$	$\frac{1}{p}$	$\frac{1-p}{p^2}$
均匀分布 Uniform(a, b)	$f(x) = \frac{1}{b-a}$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
指数分布 Exponential(λ)	$f(x) = \lambda e^{-\lambda x}$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
正态分布 $\mathcal{N}(\mu, \sigma^2)$	$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$	μ	σ^2
伽马分布 Gamma(α, β)	$f(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}$	$\frac{\alpha}{\beta}$	$\frac{\alpha}{\beta^2}$
贝塔分布 Beta(α, β)	$f(x) = \frac{x^{\alpha-1}(1-x)^{\beta-1}}{B(\alpha, \beta)}$	$\frac{\alpha}{\alpha+\beta}$	$\frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}$
卡方分布 $\chi^2(k)$	$f(x) = \frac{1}{2^{k/2}\Gamma(k/2)} x^{k/2-1} e^{-x/2}$	k	$2k$
学生t分布 $t(\nu)$	$f(x) = \frac{\Gamma((\nu+1)/2)}{\sqrt{\nu\pi}\Gamma(\nu/2)} \left(1 + \frac{x^2}{\nu}\right)^{-(\nu+1)/2}$		$\frac{\nu}{\nu-2}$ (当 $\nu > 2$)
F分布 $F(d_1, d_2)$	$f(x) = \frac{\sqrt{\frac{(d_1 x)^{d_1} d_2^{d_2}}{(d_1 x + d_2)^{d_1+d_2}}}}{x B(d_1/2, d_2/2)}$	$\frac{d_2}{d_2-2}$ (当 $d_2 > 2$)	$\frac{2d_2^2(d_1+d_2-2)}{d_1(d_2-2)^2(d_2-4)}$ (当 $d_2 > 4$)

协方差与相关系数

(X, Y) 是二维随机变量，若 $E[(X - E(X))(Y - E(Y))]$ 存在，则称其为 X 与 Y 的协方差
记为： $Cov(X, Y) = E[(X - E(X))(Y - E(Y))]$

$Cov(X, Y) > 0$ ，说明两者正相关

$Cov(X, Y) = 0$ ，说明两者不相关

$Cov(X, Y) < 0$ ，说明两者负相关

X 与 Y 独立，则两者一定不相关；但是 X 与 Y 不相关，两者不一定独立

$$D(X + Y) = D(X) + D(Y) + 2Cov(X, Y)$$

相关系数：设二维变量 (X, Y) , $D(X) > 0$ & $D(Y) > 0$

$$\text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{D(X)} \sqrt{D(Y)}} = \frac{\text{Cov}(X, Y)}{\sigma_x \cdot \sigma_y}$$

称为 X 与 Y 的相关系数，记为 ρ_{xy}

其表示的物理意义是两者的线性相关程度

另一种解释是，相关系数是 X 和 Y 标准化之后计算的协方差：

$$\text{Corr}(X, Y) = \text{Cov}\left(\frac{X - E(X)}{\sqrt{D(X)}} \cdot \frac{Y - E(Y)}{\sqrt{D(Y)}}\right)$$

大数定律

大数定律描述了随机事件在大量重复试验中的稳定性。大数定律的核心思想是：随着试验次数的增加，随机事件的样本均值会逐渐趋近于其理论期望值。

大数定律是一系列定理的总称，这些定理表明，当试验次数足够大时，随机变量的样本均值会趋近于其理论期望值。大数定律分为弱大数定律和强大数定律，它们在数学表述和收敛方式上有所不同。

独立同分布

独立同分布是指两个及以上的随机变量，它们之间满足独立性和同分布两种性质：

- 独立性：各个变量之间相互独立，联合概率密度为各个边缘概率密度累乘的形式
- 同分布：每个变量的概率分布相同，即它们的累积分布函数都一样。这说明它们的均值、方差都一样

弱大数定律

弱大数定律（Weak Law of Large Numbers, WLLN）表明，随着试验次数的增加，样本均值趋近于期望值的概率趋于1。

对于一组独立同分布的随机变量 $X_1, X_2, \dots, X_n$

均值为 μ ，方差为 σ^2

$$\text{样本均值为：} \bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

弱大数定律指出： $\lim_{n \rightarrow \infty} P(|\bar{X}_n - \mu| < \xi) = 1$

强大数定律

强大数定律（Strong Law of Large Numbers, SLLN）是一个更强的版本，它表明样本均值几乎必然地趋近于期望值。

对于一组独立同分布的随机变量 $X_1, X_2, \dots, X_n$

均值为 μ , 方差为 σ^2

$$\text{样本均值为: } \bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

弱大数定律指出: $P(\lim_{n \rightarrow \infty} \bar{X}_n = \mu) = 1$

这意味着样本均值必然收敛到期望值

中心极限定理

中心极限定理 (Central Limit Theorem, CLT) 是概率论中的一组定理, 描述了在一定条件下, 大量独立随机变量的和 (或均值) 的分布趋近于正态分布。即使这些随机变量本身不遵循正态分布, 只要满足一定条件, 它们的和或均值也会趋近于正态分布

中心极限定理不仅适用于独立同分布的随机变量, 还适用于不同分布的随机变量。只要这些随机变量满足一定的条件 (如林德伯格条件), 它们的和或均值同样会趋近于正态分布

应用:

- 统计推断: 用样本均值来估算总体均值
- A/B测试: 该定理支持了与置信区间相关的T检验和假设检验的计算和理论
- 自然现象: 测量误差、生物特征

大数定律: 描述了样本均值随着样本量的增加而趋近于总体期望值的现象, 但没有涉及样本均值的分布

中心极限定理: 不仅说明样本均值趋近于总体期望值, 还进一步指出样本均值的分布趋近于正态分布

通俗来说:

以上部分介绍的都是随机变量的理想情况, 也就是在**没有实际样本支撑**的条件下, 我们对于随机变量的分布 (概率密度函数、分布函数)、性质 (期望、方差、协方差等) 的探究。

在计算这些理想数据的时候, 我们是已知了该随机变量的一些核心要点, 比如其分布情况 (属于什么分布? 均值和方差是多少? 或者直接给出了其分布函数等)

而实际情况中, 我们并不知道这些细节信息, 所以一般是通过对数据进行采样, 然后结合一定的方法来估计随机变量的参数、分布和性质。这也就是数理统计所要关注的问题

数理统计

统计量是指不含任何参数的样本的函数，但本身它也是个随机变量
常见的统计量有：

$$\text{样本均值: } \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

$$\text{样本方差: } S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

$$\text{样本标准差: } S = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$$

$$\text{样本}k\text{阶原点矩: } \alpha_k = \frac{1}{n} \sum_{i=1}^n X_i^k$$

$$\text{样本}k\text{阶中心矩: } \beta_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$$

抽样分布：用于通过样本数据来推断总体特征

常见的抽样分布：

1、正态分布：根据大数定律和中心极限定理，样本的均值服从正态分布

2、卡方分布：

设 $X_1, X_2, \dots, X_n$ 是来自标准正态分布的样本，则统计量：

$$\chi^2 = X_1^2 + X_2^2 + \dots + X_n^2 \sim \chi^2(n)$$

称统计量 χ^2 为服从自由度为 n 的卡方分布

$$E(\chi^2) = n, \quad D(\chi^2) = 2n$$

3、t分布（学生分布）：

设 $X \sim N(0, 1)$, $Y \sim \chi^2(n)$ ，且 X 和 Y 相互独立，则：

$$t = \frac{X}{\sqrt{Y/n}} \sim t(n)$$

称统计量 t 为服从自由度为 n 的学生分布

期望为0，方差为 $n/(n-2)$

学生分布的形状类似于正态分布， n 越大，学生分布越接近于标准正态分布

4、F分布：

设 $X \sim \chi^2(n_1)$, $Y \sim \chi^2(n_2)$ ，且 X 和 Y 相互独立，则：

$$F = \frac{X/n_1}{Y/n_2} \sim F(n_1, n_2)$$

称 F 服从自由度为 (n_1, n_2) 的 F 分布

关于这四个抽样分布，有四个定理，详细见书本，感觉不会是重点

参数估计

点估计

点估计分为矩估计和最大似然估计

矩估计

假设总体 $X \sim F(x; \theta)$ ，其中 θ 是未知参数

矩估计的核心就是使用样本 k 阶原点矩来估计参数 θ

假设 $\theta = (\theta_1, \theta_2, \dots, \theta_n)$ ，那么就要构造 n 阶原点矩来计算

即建立 n 个关系式来求解参数

矩估计将 n 样本的最初 k 阶原点矩 μ 来替代 n 总体 X 的 k 阶原点矩 μ ，从而构造关系式

$$\text{样本的 } i \text{ 阶原点矩为: } \frac{1}{n} \sum_{j=1}^m X_j^i$$

$$\text{总体 } X \text{ 的 } i \text{ 阶原点矩为: } \int_{-\infty}^{\infty} x^i f(x) dx$$

$$\text{这样就构造 } n \text{ 个关系式: } \frac{1}{n} \sum_{j=1}^m X_j^i = \int_{-\infty}^{\infty} x^i f(x) dx, i = 1, 2, \dots, n$$

以求解期望和方差为例：

期望直接用样本期望代替，方差则分解为 $E(X^2) - [E(X)]^2$

其中 $E(X^2)$ 用样本的二阶原点矩代替

最大似然估计

最大似然估计的思想在于通过选择参数，使得观测数据出现的概率（似然函数）最大化

这里的观测数据就是样本 $(X_1, X_2, \dots, X_n)$

最大似然估计假设总体服从分布 $p(x; \theta)$

构造似然函数为 $L(\theta) = p(x_1; \theta)p(x_2; \theta) \dots p(x_n; \theta)$

似然函数 $L(\theta)$ 反应了样本出现的概率。

举个例子，假设一个事件发生的结果有两种可能，第一种的概率为0.8，第二种为0.2

那么当事件发生时，我们更倾向于认为是第一种结果

最大似然估计就是基于这样的思想来最大化似然函数 $L(\theta)$

通过对 $L(\theta)$ 取对数，然后求偏导为零的情况，可以得到最优的 $\hat{\theta}$

区间估计

点估计得到的是参数的近似结果，但是却没有反应关于这一近似的任何信息

区间估计可以理解为，参数落在某个区间的概率（置信度），通过这个置信度可以更加直观地判断这一近似值是否合理。

区间估计通过样本数据对总体参数进行估计，并给出一个估计值的范围（即区间），同时附带一定的置信水平。区间估计的核心思想是：虽然我们无法通过样本精确地估计总体参数，但可以通

过样本数据构造一个区间，使得该区间以较高的概率包含总体参数的真实值。
区间的范围要多大才好？区间估计的可信程度怎么样？

设总体分布函数 $F(x; \theta)$ 含有一个未知数 θ ，对于给定值 α

若由样本 $X_1, X_2, \dots, X_n$ 确定的两个统计量

$$\underline{\theta} = \underline{\theta}(X_1, X_2, \dots, X_n)$$

$$\bar{\theta} = \bar{\theta}(X_1, X_2, \dots, X_n)$$

满足： $P\{\underline{\theta} = \underline{\theta}(X_1, X_2, \dots, X_n)\} < \theta < P\{\bar{\theta} = \bar{\theta}(X_1, X_2, \dots, X_n)\}$

称区间 $(\underline{\theta}, \bar{\theta})$ 为 θ 的置信水平为 $1 - \alpha$ 的置信区间

区间估计给出了参数估计的可信程度，从而在参数选择中可以得到更多的信息
具体的参数估计方法见书本，个人认为并非重点